Исследование и развитие технологий автогенерации кода для GPU в применении к задачам тензорной аппроксимации. Алгоритм ALS

Кузнецов М.А.

20 мая 2013

Утверждения

- Тензорные алгоритмы сложные и требуют больших вычислительных затрат
- GPU обладают большой мощностью в плане вычислений

Отсюда логичный вывод — попытаться писать код алгоритма для GPU

Код для GPU — особенности

У программирования для GPU есть свои плюсы и минусы

“+”

- Возможность использования множества процессоров
- Возможность серьезного ускорения программы

“-”

- Очень длительный процесс написания кода
- Сложность написания кода
- Платформенно-зависим

Пример кода для GPU

```
__kernel void __attribute__ ((reqd_work_group_size(16, 1, 1)
{
  float acc_j_outer_j_inner_k_outer_k_inner;

  if ((-1 + -16 * gid(0) + -1 * lid(0) + n) >= 0)
  {
    acc_j_outer_j_inner_k_outer_k_inner = 0.0f;
    for (int j_inner = 0; j_inner <= 15; ++j_inner)
      for (int k_inner = 0; k_inner <= 15; ++k_inner)
        for (int k_outer = 0; k_outer <= (-1 + -1 * k_inner
          for (int j_outer = 0; j_outer <= (-1 + -1 * j_inne
            acc_j_outer_j_inner_k_outer_k_inner = acc_j_oute
    f[n * (lid(1) + gid(1)) + lid(0) + gid(0) * 16] = acc_j
  }
```

Идея автоматической генерации

Код на OpenCL сложный, нужно учитывать барьеры, разбиение и вычислительные сетки. Поэтому логично использвать пакеты автоматической генерации кода. Использован новый, активно разрабатывающийся пакет loo.py

Почему Python

Вообще говоря, Python медленный язык. Почему же его можно использовать для ускорения работы программ? Однако:

- Python обладает большим количеством стандартных модулей
- Использование модулей дает возможность получить скорость C-кода
- Простой синтаксис языка позволяет быстро писать программы даже для сложных алгоритмов
- Экономит время программиста

Пакет Loo.py

Пакет loo.py разрабатывается Андреасом Клекнером (Andreas Kloekner). http://gitlab.tiker.net/inducer/loopy Вышеуказанный репозиторий — закрытый, однако автор включен в список “разработчиков”. Стабильную версию можно найти здесь http://git.tiker.net/loopy.git

Пакет предназначен для “развертки” циклов и последующей генерации OpenCL кода. Для этого нужно сформулировать ядро в специальном синтаксисе.

Как правильно сформулировать алгоритм

Для применения пакета loo.py алгоритм должен быть формализован и записан в виде вложенных циклов:

```
for i in xrange(...):
     for j in xrange(....):
...............
          for k n xrange(....):
            ............
```

Пример ядра

```
def Prav_U(ctx):
  order='C'
  dtype = np.float32
  knl = lp.make_kernel(ctx.devices[0],
  [

    "{[i,j,k,alpha]: 0<=alpha<r and 0<=i,j,k<n}",

  ],
  [
    "f[alpha,i]=sum((j,k), a[i,j,k]*v[alpha,j]*w[alpha,k])"
  ],
  [
    lp.GlobalArg("a", dtype, shape="n, n, n", order=order),
```

```
lp.GlobalArg("v", dtype, shape="r, n", order=order),
    lp.GlobalArg("w", dtype, shape="r, n", order=order),
    lp.GlobalArg("f", dtype, shape="r, n", order=order),
    lp.ValueArg("n", np.int64),
    lp.ValueArg("r", np.int64),
  ],
  assumptions="n>=1")
  knl = lp.split_iname(knl, "i", 16,outer_tag="g.0", inner_t
  knl = lp.split_iname(knl, "alpha", 1, outer_tag="g.1", in
  knl = lp.split_iname(knl, "j", 16)
  knl = lp.split_iname(knl, "k", 16)
  print lp.CompiledKernel(ctx, knl).get_highlighted_code()
  return knl
```

Актуальность исследования

Привлекательность исследования обусловлена несколькими факторами:

1. Тензорные алгоритмы начали активно разрабатываться в последнее время
2. Написание GPU-кода — сложная задача, существует необходимость исследовать возможности автогенерации GPU-кода
3. Вычислительная мощность GPU превосходит многоядерные CPU, использование GPU эффективней

Ввиду того, что процесс написания GPU-кода вручную длительный и трудоемкий, хоть и эффективный, в вычислительных задачах хотелось бы использовать следующий “идеальный” способ его написания:

1. Использование в динамических языках (Python)
2. Автоматическое распараллеливание стандартных задач (циклов), генерация OpenCL/CUDA-кода
3. Быстрый процесс написания кода

Цель работы

- Научиться использовать пакет loo.py
- С помощью пакета получить эффективную параллельную реализацию алгоритма ALS
- Научиться “параллелить” тензорные алгоитмы

Метод ALS: идея

Основная идея алгоритма, состоит в том, чтобы фиксировать все факторы, кроме одного, канонического разложения и искать минимум функционала

$$F = \sum_{i,j,k=1} (A_{ijk} - \sum_{\alpha=1}^{r} U_{i\alpha} V_{j\alpha} W_{k\alpha})^2.$$

только по нему. Путем циклических перестановок, используя уже полученные факторы, строятся последующие, до тех пор, пока не будет достигнута требуемая точность аппроксимации или, пока не сработают другие критерии остановки алгоритма

Формулы метода ALS

Найдем частную производную функционала F по $U_{\hat{i}\hat{\alpha}}$ и приравняем ее к 0:

$$\frac{\partial F}{\partial U_{\hat{i}\hat{\alpha}}} = 2\Big(\sum_{i,j,k}(A_{ijk} - \sum_{\alpha} U_{i\alpha}V_{j\alpha}W_{k\alpha})\Big)\Big(-\sum_{\check{\alpha}}(V_{j\check{\alpha}}W_{k\check{\alpha}})\frac{\partial U_{i\check{\alpha}}}{\partial U_{\hat{i}\hat{\alpha}}}\Big) = 0;$$

$$\frac{\partial U_{i\check{\alpha}}}{\partial U_{\hat{i}\hat{\alpha}}} = \delta_{i,\hat{i}}\delta_{\check{\alpha}\hat{\alpha}};$$

Окончательно, получаем следующие соотношения:

$$\sum_{j,k} A_{\hat{i}jk}V_{j\hat{\alpha}}W_{k\hat{\alpha}} = \sum_{j,k,\alpha} U_{\hat{i}\alpha}V_{j\alpha}W_{k\alpha}V_{j\hat{\alpha}}W_{k,\hat{\alpha}},$$

Формулы ALS

Обозначим через $M_{\alpha\hat{\alpha}}$ матрицу с элементами

$$M_{\alpha,\hat{\alpha}} = (\sum_j V_{j,\alpha} V_{j\hat{\alpha}})(\sum_k W_{k\alpha} W_{k\hat{\alpha}}); \quad (1)$$

тогда

$$\sum_\alpha U_{\hat{i},\alpha} M_{\alpha,\hat{\alpha}} = \sum_{j,k} A_{\hat{i},j,k} V_{j,\hat{\alpha}} W_{k,\hat{\alpha}}; \quad (2)$$

Через $F_{i,\hat{\alpha}}$ обозначим правую часть. Тогда, имеем

$$\sum_\alpha U_{\hat{i}\alpha} M_{\alpha\hat{\alpha}} = F_{i\hat{\alpha}}. \quad (3)$$

В виде системы

или в виде системы линейных уравнений

$$UM = F. \tag{4}$$

где $M \in \mathbb{R}^{r \times r}$.

В ходе экспериментов использовались следующие платформы:

- Мобильная видеокарта NVIDIA
- Мобильный процессор Intel Core i5
- Кластер Tesla ИВМ РАН

Характеристики Tesla

Device Tesla C2070	
NAME:	Tesla C2070
VENDOR:	NVIDIA Corporation
VERSION:	304.54
VERSION:	OpenCL 1.1 CUDA
OPENCL_ C_ VERSION:	OpenCL C 1.1
MAX_ WORK_ GROUP_ SIZE:	1024
ADDRESS_ BITS:	32
MAX_ MEM_ ALLOC_ SIZE:	1343 MByte
GLOBAL_ MEM_ SIZE:	5375 MByte

Таблицы времен

Для фиксированного ранга $r = 3$ и размерности тензора n исследована скорость выполнения как отдельных ядер, так и всего алгоритма ALS. Однако ALS алгоритм не гарантирует сходимость, только убывание невязки, поэтому будем указывать только время выполнения одной итерации. Приведем таблицу с временем выполнения.

размер n	128	256	512	756
t_r	0.013803	0.08674	0.65225	0.92513
t_l	0.00035595	0.0004210	0.000552	0.000673
t_{solve}	0.00025391	0.00025510	0.000256	0.000256
LU	0.00024890	0.0002851	0.00035	0.000391
T_i	0.026740	0.1834	1.08289	1.92985

Приведем также таблицу с временем выполнения одной итерации программы, вычисления правой части в зависимости от ранга r и фиксированной размерности тензора $n = 128$

ранг r	3	6	10	20
t_r	0.01380	0.0152	0.0162	0.0184
T_i	0.04326	0.0437	0.0468	0.0556

График

Для наглядности также построим графики поведения времени вычисления правой части на CPU, мобильном GPU и Tesla:

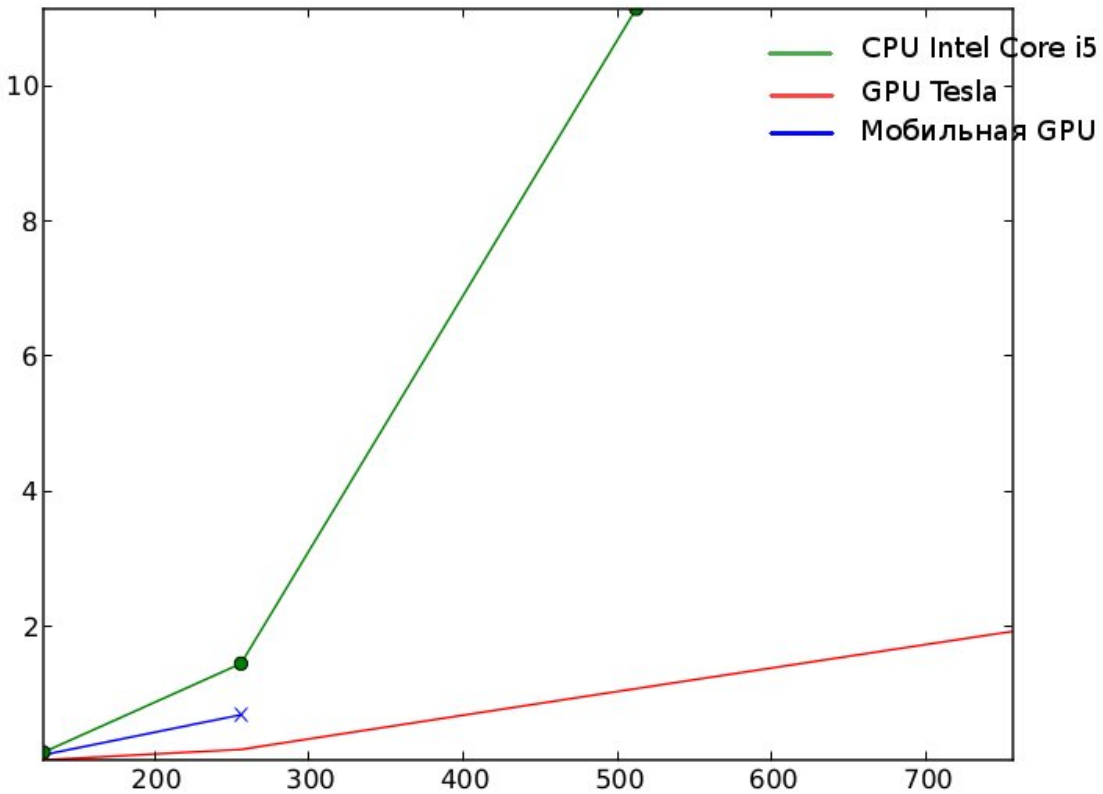

В ходе выполенииния работы были получены следующие результаты:

1. Изучен пакет автоматической генерации OpenCL-кода
2. Реализованы алгоритмы:
   - LU-разложения, решения систем в стандартном виде LU
   - подсчета правой части алгоритма ALS
   - ALS-алгоритм

Важные выводы

Ключевые выводы:

1. Генерировать OpenCL код можно автоматически
2. Сильно экономится время, а качество реализации не страдает
3. Можно избежать ошибок “технического” характера
4. Можно параллелить произвольный алгоритм, записанный в нужном формате

Планы

- Оптимизировать имеющийся код
- На основе имеющегося опыта распараллелить другие тензорные алгоритмы
- Написать небольшую статью совместно с Андреасом Клекнером

Вопросы

Спасибо за внимание! Ваши вопросы?